설비 고장 예측 모델 개발

[Autoencoder 비지도학습 비지도학습 기반 설비 이상 감지]

발표자 장현진

contents

01 Project Overview
02 Dataset Analysis
03 Model Comparison
04 Optimization
05 Final Model Performance
06 Business Impact
07 Conclusion

AI4I 2020 제조업 이상 탐지 시스템 개발

비지도학습 기반 설비 이상 감지 및 성능 개선 전략

What

- 비지도 학습 기반 이상 탐지(autoencoder) 모델을 활용하여 라벨 없이 설비 고장 징후를 조기 포착
- 설비 이상 탐지 → 사전 예방 정비(PdM, Predictive Maintenance) 가능하게 하기 위한 사전 단계 기술 확보

Why

- 실제 생산 현장에서는 고장 데이터가 부족하거나 라벨링이 안 되어 있는 경우가 많음
- 비지도 학습은 학습 초기 데이터셋 가용성 문제를 우회할 수 있는 훌륭한 솔루션
- 고장이 점진적으로 발생하는 현상 특성을 반영해 데이터 증강을 통한 고장 재현율 보완도 실험

How

- 정상 데이터만 활용해 Autoencoder 학습 → 재구성 오차를 기준으로 이상 탐지
- 임계값 최적화, 데이터 증강(가짜 고장 샘플 추가), SMOTE 등 클래스 불균형 완화 기법 비교 실험
- 라벨이 있는 20% 데이터셋으로 성능 평가: AUC, 재현율(Recall), F1-score 중심

센서 데이터 특성 및 불량 라벨 구조 분석

데이터셋 개요

- **센서 데이터**

  5개 연속형 변수 (온도, 토크, 회전속도, 마모량)

Feature	Unit
Air temperature	K
Process temperature	K
Torque	Nm
Rotational speed	rpm
Tool wear	min

- **불량 라벨 구조**

  5가지 고장 유형의 OR 조합

Label	Description
TWF	Tool Wear Failure
HDF	Heat Dissipation Failure
PWF	Power Failure
OSF	Overstrain Failure
RNF	Random Failure
Machine_failure	OR 조건으로 전체 불량 여부

출처: UCI Machine Learning Repository
데이터 규모: 총 10,000개 샘플, 불량 339개 (3.4%)

Dataset

UDI	Product ID	Type	Air temperature [K]	Process temperature [K]	Rotational speed [rpm]	Torque [Nm]	Tool wear [min]	Machine failure	TWF	HDF	PWF	OSF	RNF
1	M14860	M	298.1	308.6	1551	42.8	0	0	0	0	0	0	0
2	L47181	L	298.2	308.7	1408	46.3	3	0	0	0	0	0	0
3	L47182	L	298.1	308.5	1498	49.4	5	1	1	0	0	1	0
4	L47183	L	298.2	308.6	1433	39.5	7	0	0	0	0	0	0
5	L47184	L	298.2	308.7	1408	40	9	0	0	0	0	0	0
6	M14865	M	298.1	308.6	1425	41.9	11	1	0	0	1	0	0
7	L47186	L	298.1	308.6	1558	42.4	14	0	0	0	0	0	0
8	L47187	L	298.1	308.6	1527	40.2	16	0	0	0	0	0	1
9	M14868	M	298.3	308.7	1667	28.6	18	0	0	0	0	0	0
10	M14869	M	298.5	309	1741	28	21	0	0	0	0	0	0
11	H29424	H	298.4	308.9	1782	23.9	24	0	0	0	0	0	0
12	H29425	H	298.6	309.1	1423	44.3	29	0	0	0	0	0	0
13	M14872	M	298.6	309.1	1339	51.1	34	0	0	0	0	0	0

출처: UCI Machine Learning Repository
데이터 규모: 총 10,000개 샘플, 불량 339개 (3.4%)

데이터 불균형 및 특성 분석

불량/정상 비율, Feature 상관관계, Product Type별 차이

심각한 클래스 불균형

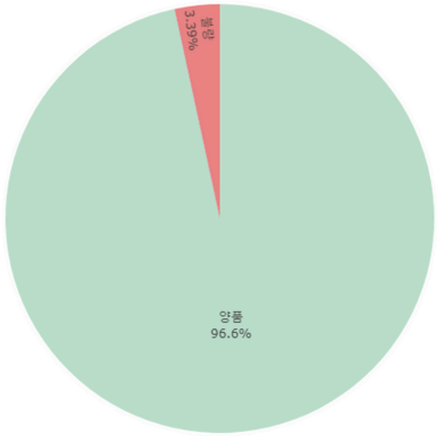

강한 Feature 상관관계

: 온도 간 0.88, 토크-회전속도 간 -0.88

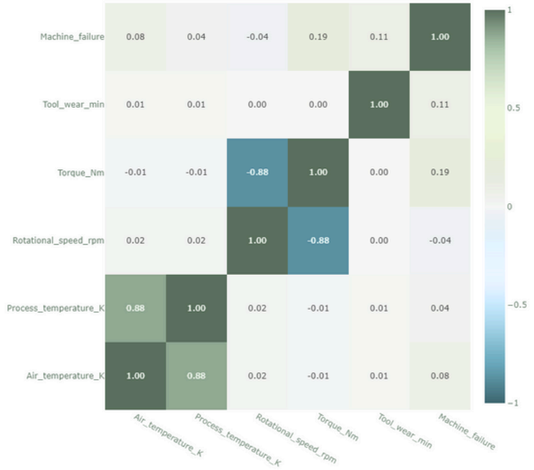

Product Type별 센서값 차이

: H/L/M 타입 간 유사한 평균값 유지

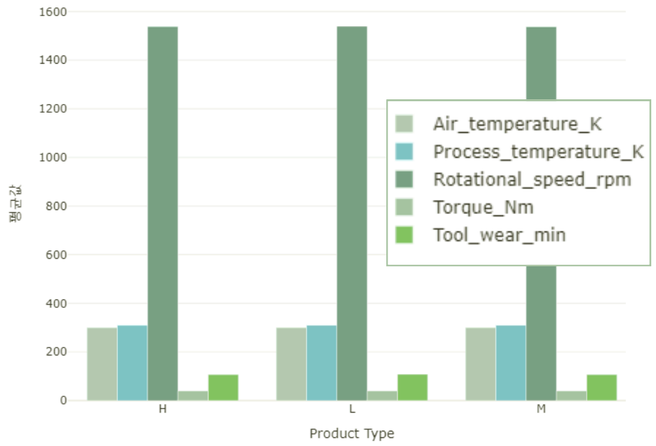

(smote) 불량 데이터 증강 검토 / 가상 시계열 데이터 생성하여 불량 재현율 수치 추가로 확인
다차원 비지도학습이므로 삭제하지 않고 패턴을 그대로 학습
Product Type은 학습에 반영하지 않음

Feature별 데이터 분포 특성

센서값 분포 패턴 확인 및 데이터 품질 검증 결과

순수 분포 특성
라벨 무관한 각 센서의 통계적 특성

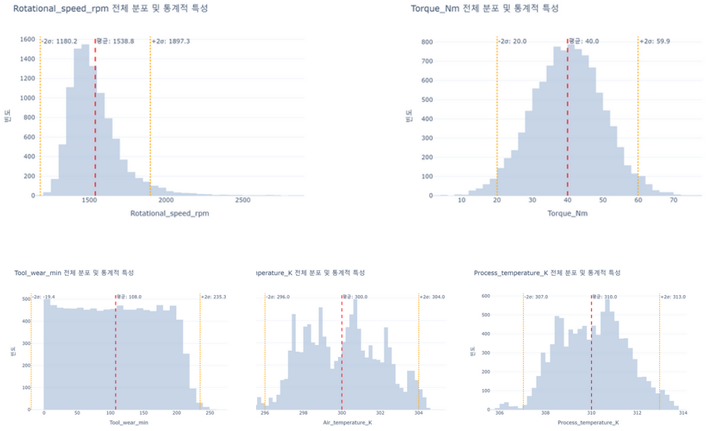

이상치
IQR 기준 이상치 → 불량 데이터 100%

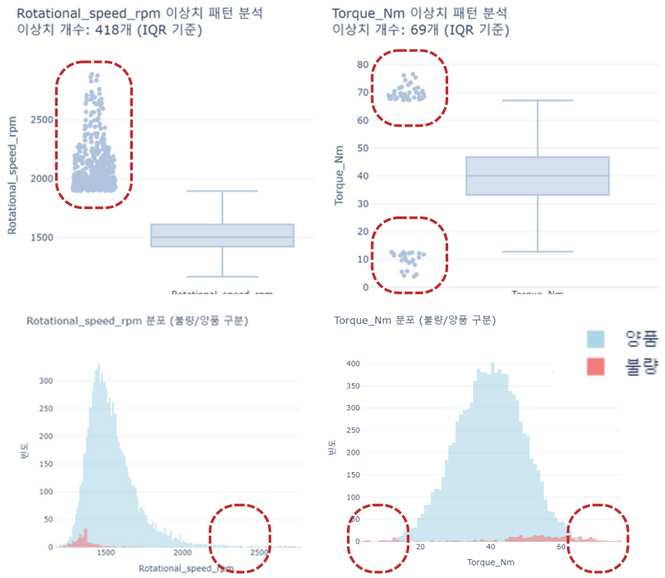

결측치, 물리적 한계 이상 데이터 확인
깨끗한 데이터 100%

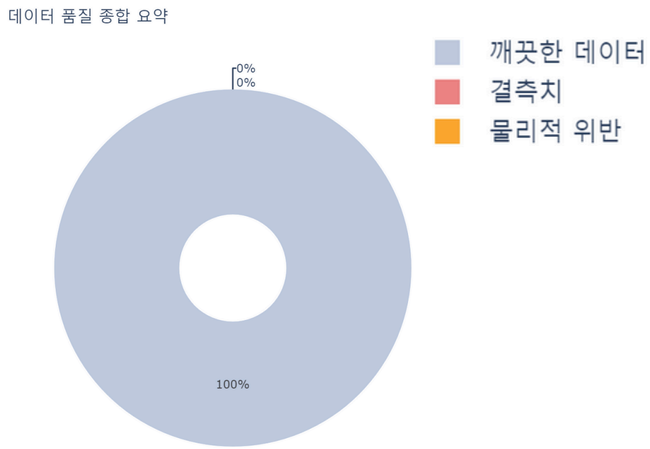

이상치의 경우 고장 예측에 가장 중요한 정보 : 보존해야 할 이상치

결측치, 물리적 한계 위반 데이터 점검 : 이상 없음 (깨끗한 데이터 100%)

학습/테스트 데이터 분할 전략

Stratified Split을 통한 균등 분포 보장

10,000	9,661	339	5
전체 데이터 (개)	정상 데이터 96.6%	불량 데이터 3.4%	불량 타입 (종류)

데이터 특징 및 주요 과제

클래스 불균형 : 정상 데이터 패턴을 학습하기 위한 비지도 학습 접근 가능
다양한 불량 타입: 총 5가지 고장 패턴 학습 필요
소수 클래스 문제: RNF (19개, 5.6%)와 TWF (46개, 13.6%)는 데이터 수가 매우 적음
복합 불량 존재: 24개의 복합 불량 케이스 존재

모델링 방향: Autoencoder와 같은 이상치 탐지 모델
최적의 임계값(Threshold) 설정 필요
불량 타입별 세부 성능 분석을 통해 모델 개선 방향 도출 필요

전체 데이터 분할

구분	학습용 (80%)	테스트용 (20%)	총계
정상	7,728개	1,933개	9,661개
불량	271개	68개	339개
총계	**7,999개**	**2,001개**	**10,000개**

불량 타입별 학습/테스트 분할

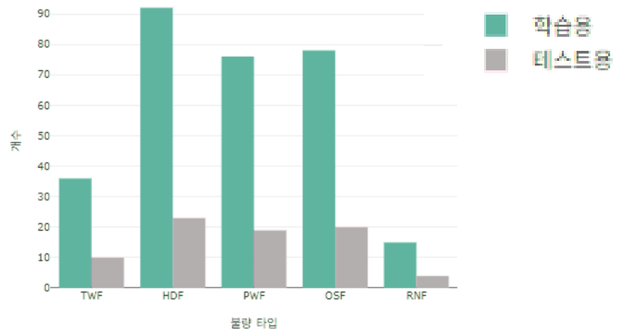

03 Model Comparison

초기 모델 성능 비교 (9가지 시나리오)

데이터 증강 전략 × 임계값 조합 성능 분석

Dataset:

증강 3단계 : 원본 / 불량 전체 증강 / 소수 2개 불량 증강

임계값 : 85% / 90% / 95%

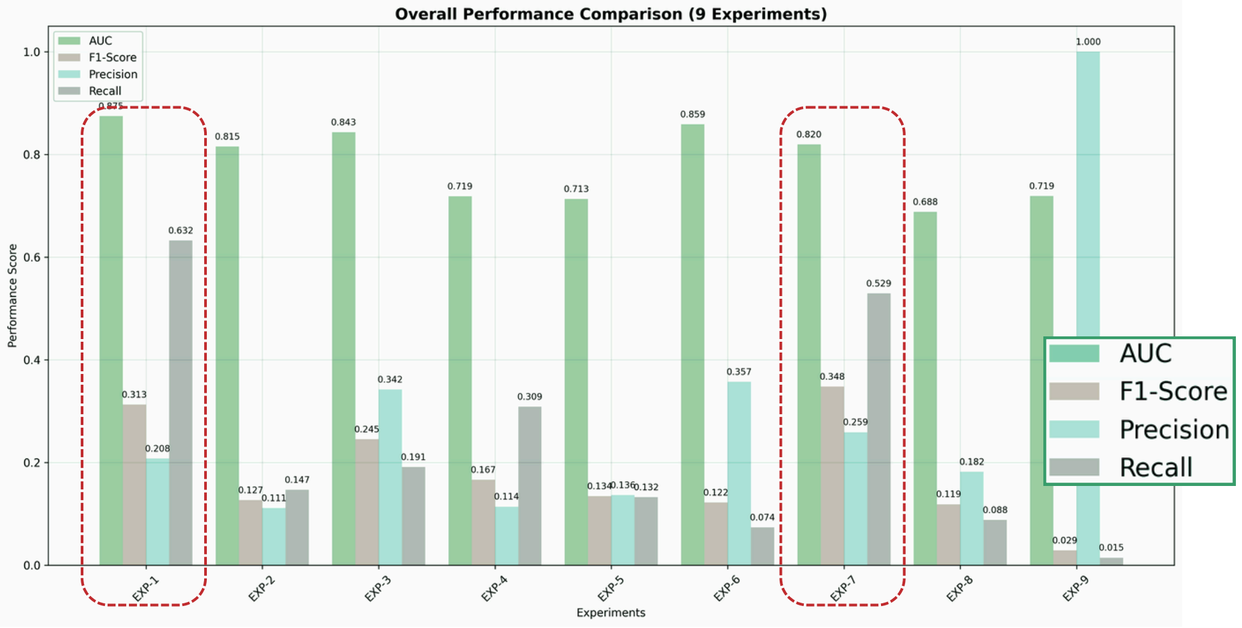

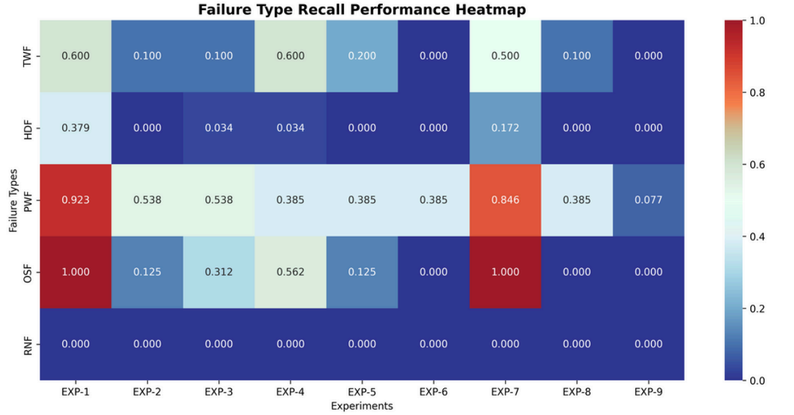

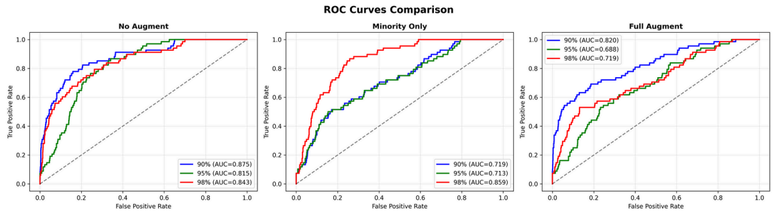

exp1 , exp 7 성능 가장 우수 : AUC 0.8 이상 & Recall 0.5 이상
(원본 + 임계값 85%, 불량 전체 증강 + 임계값 85%)

RNF(Random False) : 예측하지 못하는 데이터
→ 9가지 모든 경우의 수에서 RNF 불량 검증 불가능

03 Model Comparison

불량 데이터 항목별 증강 비교 분석

RNF : 예측 불가능 불량 패턴

불량 데이터 증강 시 RNF 포함 여부에 따른 성능 평가

Dataset:

1. 원본 데이터셋
2. RNF 제외 4개 불량 1.5배 증강
3. RNF 제외 4개 불량 최대값 115개 기준으로 차등 증강
4. RNF 포함 5개 불량 최대값 115개 기준으로 차등 증강

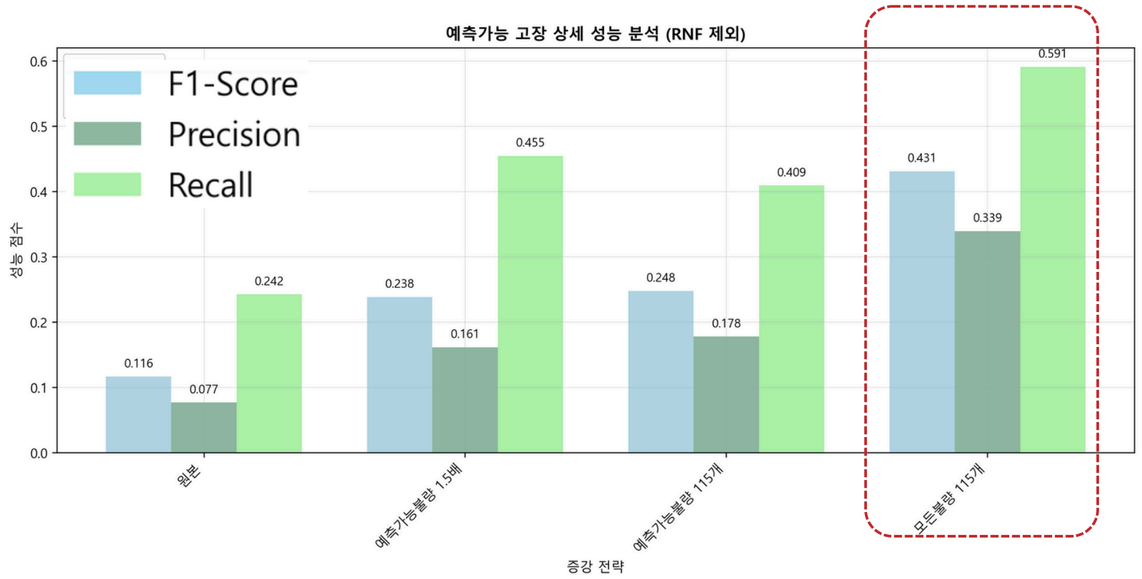

Random False 포함 115개 증강 학습 시 성능 가장 우수
F1 Score 0.431 , Recall 0.591

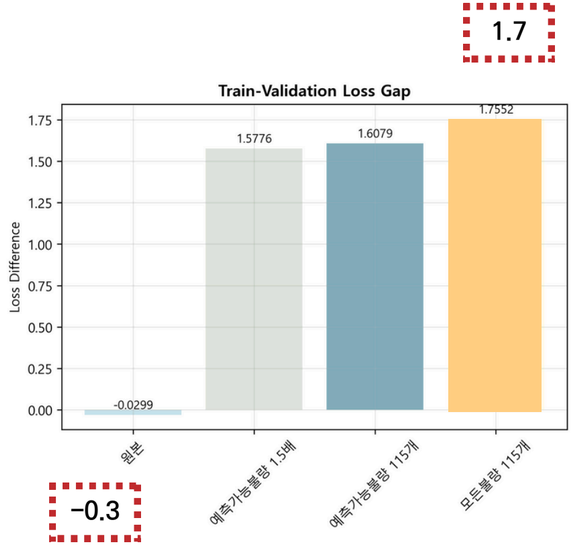

train-valid loss 차: −0.3 → 1.7 (증강 시 2.0 증가)
심각한 과적합

03 Model Comparison

증강 방법론 비교 검증

SMOTE 3가지 vs 보수적 증강 성능 대결

Dataset: 임계값 90% 고정

1. 원본_증강없음: 증강 없는 원본 데이터
2. RNF 제외 증강 / RNF 포함 증강
3. SMOTE 균등화 / 비례 증강
4. 보수적 균등화 / 비례 증강

균등화 : 모든 불량을 115개로 증강

비례 증강 : 기존 비율 유지하며 1.5배 증강

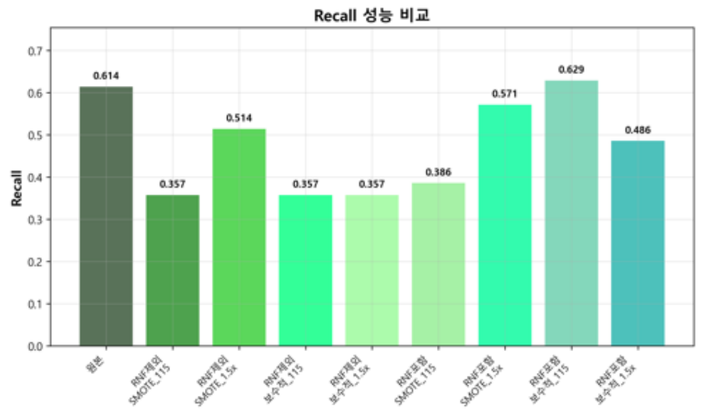

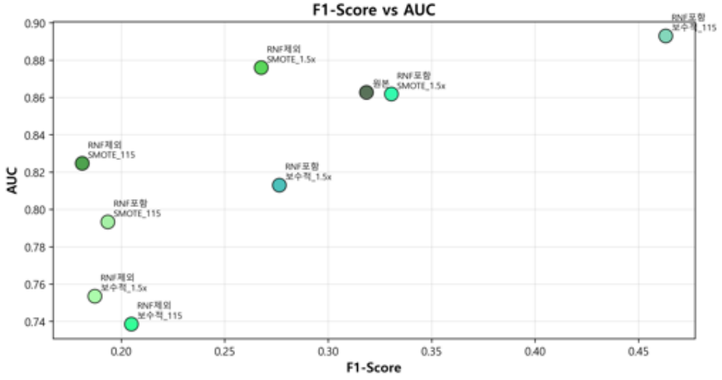

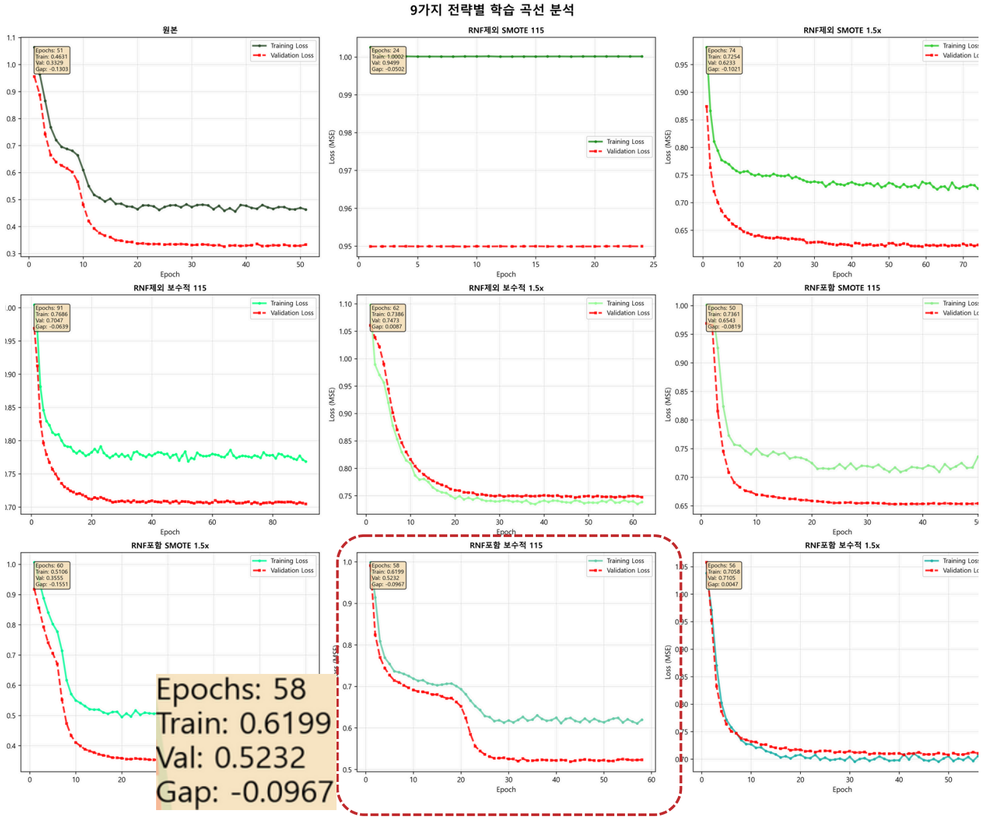

1. RNF 불량 제외 후 4개 세부 불량만 증강한 모델은 전체적인 성능이 떨어짐

2. 보수적 증강의 경우 설비 도메인 원리 내에서 증강하기 때문에 성능 향상에 도움이 된 것으로 추정

3. 균등화 / 비례 증강의 경우,

최종 모델 선정 및 근거

선택 이유 및 성능 검증

최종 모델 : RNF포함_보수적_115개통일 Autoencoder

목표: 제조 공정 데이터(ai4i2020) 기반 이상 탐지 (불량 예측)
모델 타입: 딥러닝 오토인코더 (Autoencoder)
주요 특징:
모든 불량 유형(TWF, HDF, PWF, OSF, RNF 포함)에 대해 '보수적 증강' 적용
학습 데이터에서 각 불량 유형별 샘플 수를 115개로 균등화
정상/불량 이진 분류 형태로 학습 및 평가 (오토인코더 재구성 오류 기반)

Model Setting

Epochs: 100 (최대)
Batch Size: 32
Early Stopping:
monitor='val_loss'
patience=15
restore_best_weights=True

ENCODING_DIM = 3
HIDDEN_DIM = 2
DROPOUT_RATE = 0.1
LEARNING_RATE = 0.001
VALIDATION_SPLIT = 0.2
EARLY_STOPPING_PATIENCE = 15

증강 방법 (도메인 지식 기반 파라미터 설정):

노이즈 추가: 가우시안 노이즈 (평균 0, 표준편차: 원본값 × 0.05)
스케일링: 원본값 기준 ±8% 범위 내 랜덤 스케일 (0.92 ~ 1.08 배)
시프트: 원본값 기준 ±5% 범위 내 랜덤 시프트

F1 Score: 0.4216
Precision: 0.3391
Recall: 0.5571
AUC: 0.8970

Hyperparameter Tuning

Architecture, Learning Rate, Batch Size 등 튜닝 결과

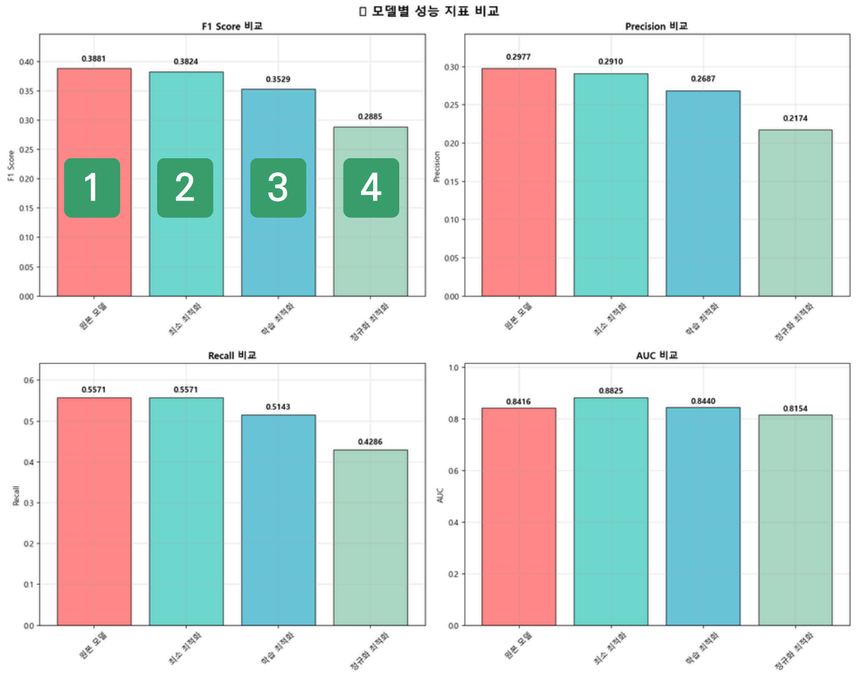

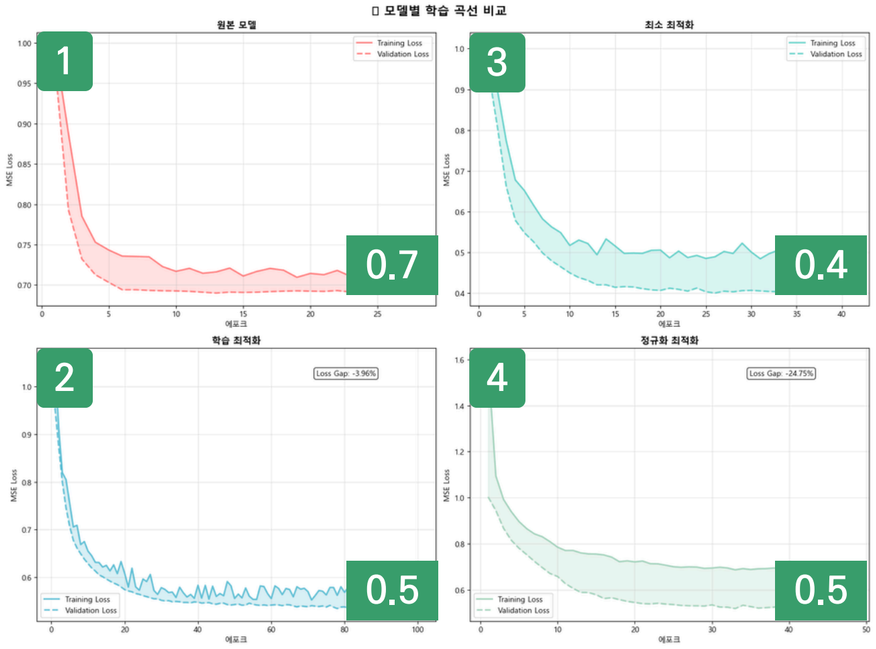

1 원본 (튜닝 전)

2 모델 복잡도 증가

ENCODING_DIM: 3 → 5
HIDDEN_DIM: 2 → 4

3 학습 최적화

Learning Rate
: 0.001 → 0.0005 (50% 감소)
Batch Size: 32 → 16 (50% 감소)
Early Stopping Patience
: 15 → 25 (67% 증가)

4 정규화 강화

DROPOUT_RATE
: 0.1 → 0.3 (3배 증가)
L2 정규화 추가 (kernel_regularizer)
Batch Normalization 추가

최종 손실률 0.5 미만 & 최고 AUC 를 보이는 설정 값으로 모델 튜닝 종료

최종 모델 성능 분석

혼동행렬, loss gap, ROC 곡선, MES Shift Ratio

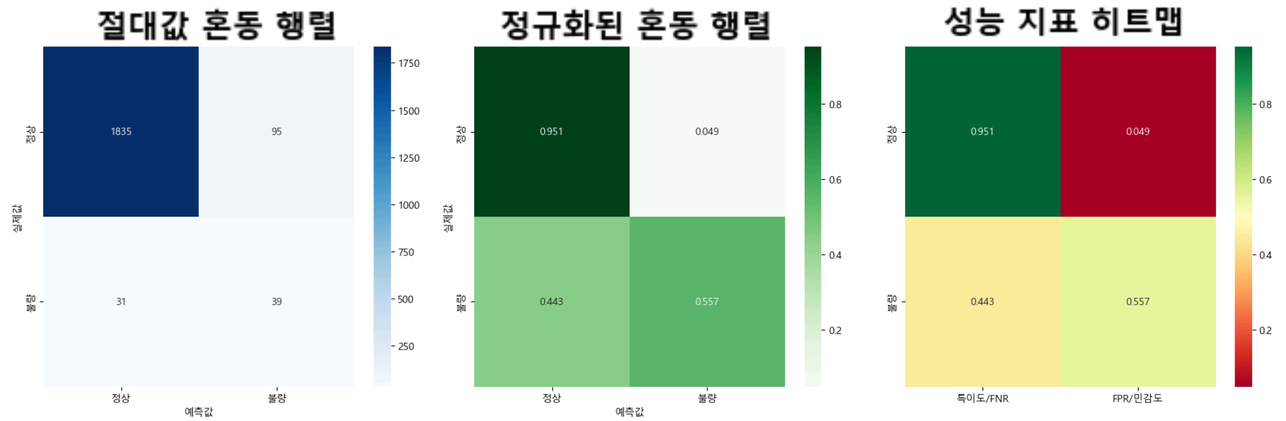

정상 예측률 95%, 불량 예측률 55%
AUC 0.88
loss gap −0.08 : 과적합 없음
AUC CV 결과 0.84±0.05 (변동계수 6.3%) : 안정
MSE Shift Ratio (%) −72% : 일반화 성능 우수

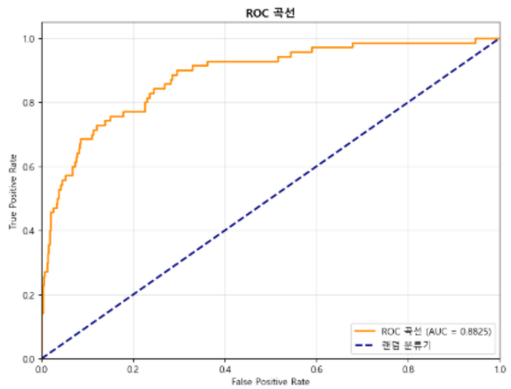

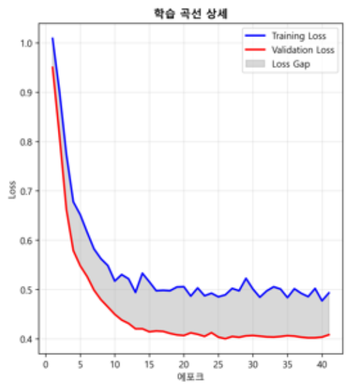

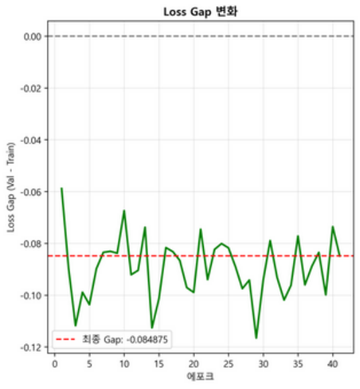

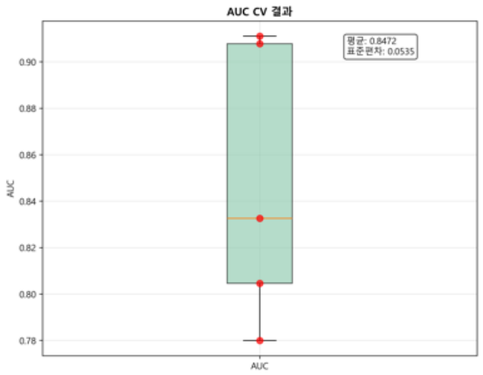

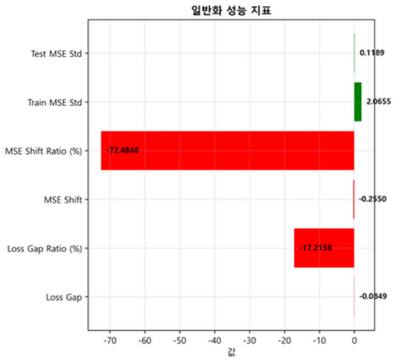

Failure Case Analysis

False Positive/Negative 패턴 분석 및 개선 방안

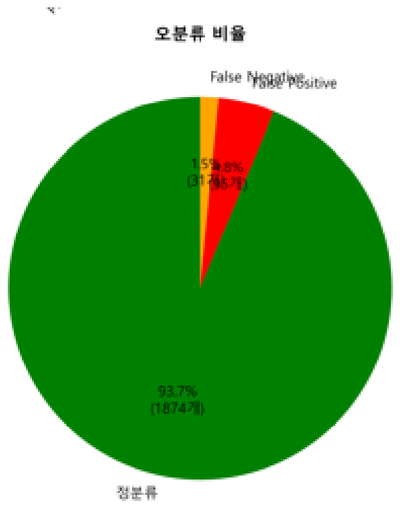

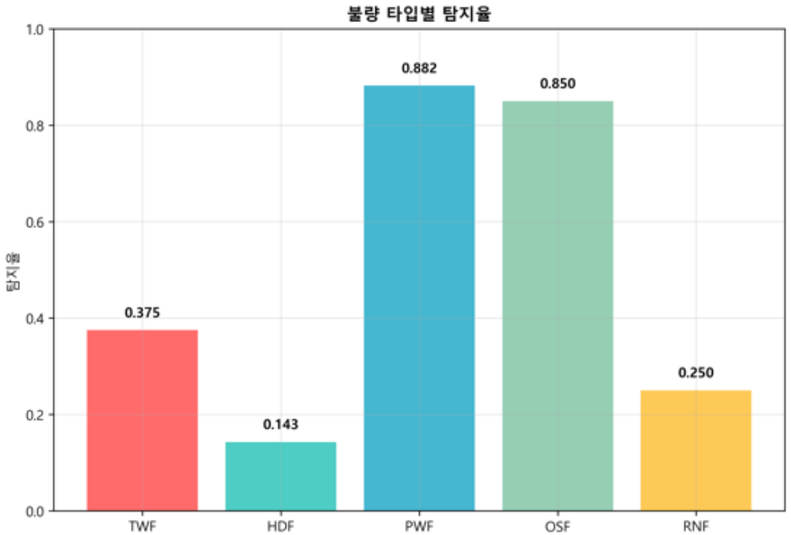

불량 타입	추정 원본 개수	탐지율	상관성 분석
PWF	~90개	88.2%	충분한 원본 데이터 → 높은 성능
OSF	~85개	85.0%	충분한 원본 데이터 → 높은 성능
TWF	~45개	37.5%	중간 데이터 → 중간 성능
RNF	~20개	25.0%	부족한 데이터 → 낮은 성능
HDF	~15개	14.3%	매우 부족한 데이터 → 최저 성능

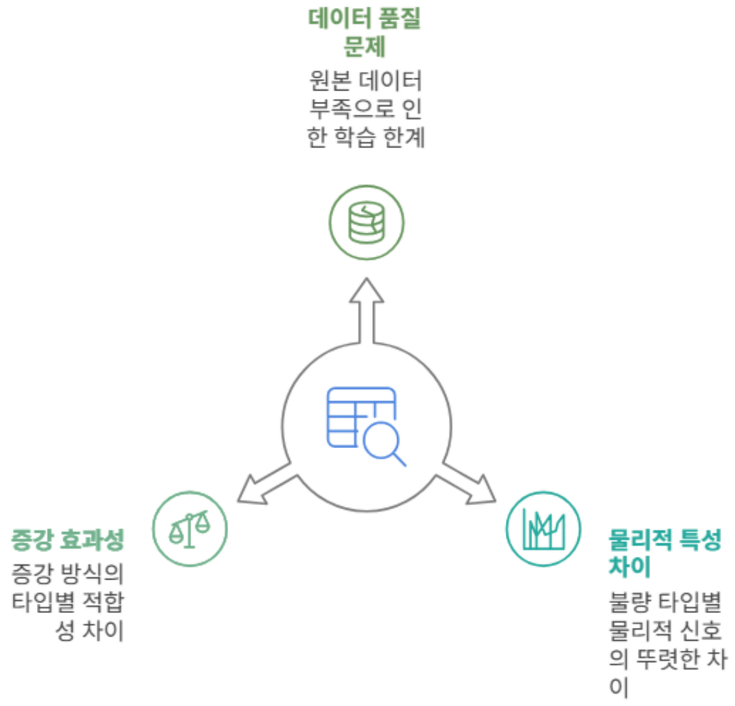

Threshold Optimization

임계값 최적화 및 운영 전략

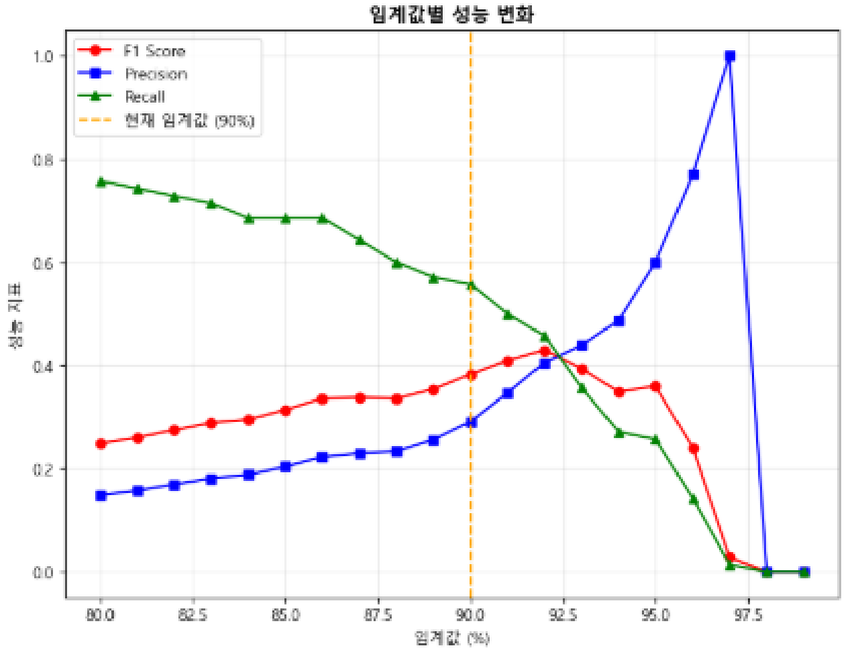

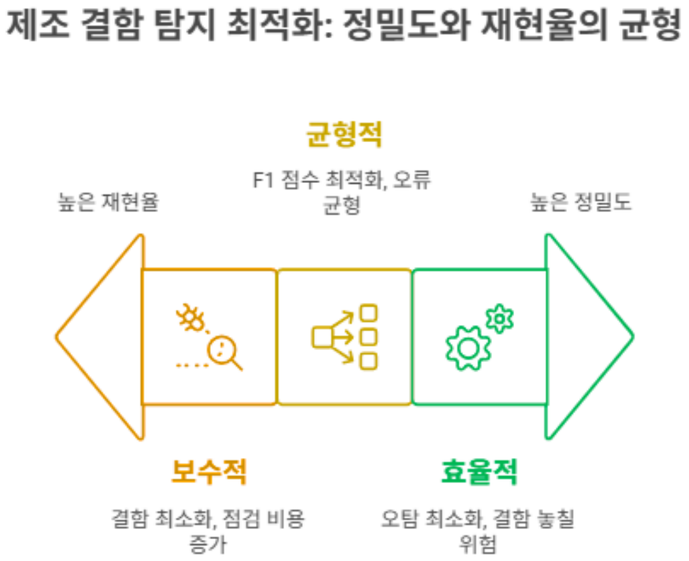

80–85% 구간: Precision 하락, Recall 상승 (False Positive 증가) : 결함 최소화 점검 비용 증가
90–95% 구간: Precision 상승, Recall 하락 (False Negative 증가) : 오탐 최소화 결함 유출 위험
95% 이상: 극도로 보수적 탐지 (놓치는 불량 급증)

한계점 및 향후 개선 방안

현재 모델의 제약사항 및 발전 방향

모델 한계

운영 적응성 한계
정적 모델 구조와 해석 가능성 부족

데이터 관련 한계
데이터 불균형과 증강 방식의 한계

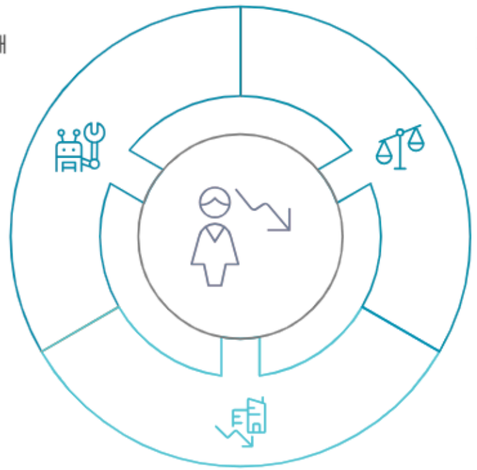

구조적 한계
모델 구조와 임계값 설정의 한계

즉시 → 장기

타입 기반 임계값
기존 모델을 활용하여 탐지율을 빠르게 개선.

HDF/RNF 모델
새로운 모델 학습을 통해 빠른 성능 향상.

데이터 수집
지속적인 데이터 개선으로 근본 원인 해결.

GAN 데이터 생성
고급 합성 방법을 사용하여 데이터 부족 문제 해결.

물리 공학
도메인 전문 지식과 분석을 활용하여 성능 향상.

앙상블 시스템
모델 통합을 통해 전체 시스템 안정성 향상.

온라인 학습
지속적인 성능 유지를 위해 변화에 지속적으로 적응.

설명 가능한 AI
자동화된 실패 분석을 통해 부가 가치를 제공.

자동화 파이프라인
자동화된 워크플로우로 운영 효율성 극대화.

데이터 임계값 기준 설정을 위한 ROI 계산 필요
적은 불량 데이터와 타입별 불균형 개선을 위한 모델 앙상블 / 타입별 특성 반영한 정교한 데이터 증강 / 생산 환경 맞춤 방안으로 발전 필요

감사합니다

발표자 장현진