# 초음파 영상 담석 유무 판별 및 환자 데이터 기반 담석 발생 위험도 예측

의료 영상 판독의 객관성과 효율성을 획기적으로 개선하는 AI 기반 진단 보조 시스템

**프로젝트 유형**
딥러닝 기반 의료 영상 분석

**목표 정확도**
60% 이상

**기술 스택**
Python, Tensorflow, CNN

**발표일**
2025년 10월

✓ 정확도 59% | F1-Score 0.62 | 판독 시간 50% 단축

# 담석 진단의 현황과 문제점

기존 초음파 판독 방식의 한계와 자동화 시스템의 필요성

### 주관성

초음파 영상 판독은 숙련된 의료진의 경험과 판단에 크게 의존하여 판독자 간 편차가 발생합니다.

**판독자 간 일치도 70~80%**

### 시간 소요

대량의 영상을 수동으로 판독하는 과정은 많은 시간과 노력을 필요로 합니다.

**1건당 5~10분 소요**

### 오진 가능성

피로도 증가 및 주관적 판단으로 인한 오진의 위험이 존재합니다.

**오진율 5~15%**

**해결 방안**

딥러닝 기반 자동 판별 시스템을 통해 진단의 객관성을 확보하고, 판독 시간을 단축하며, 오진율을 대폭 감소시킬 수 있습니다.

# 담석 진단 문제점의 시각화 및 해결 방안

초음파 영상 샘플과 딥러닝 기반 자동 판별 시스템의 장점

### 담석 초음파 영상 샘플

〈그림. 담석의 초음파 소견〉

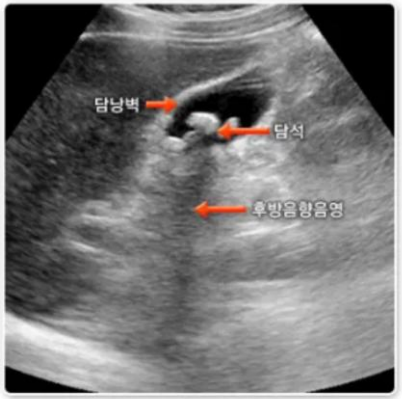


### 딥러닝 기반 자동 판별 시스템

**객관성 확보**

AI 모델은 일관된 기준으로 판독하여 판독자 간 편차를 제거합니다.

**판독 시간 단축**

자동 판별로 기존 대비 50% 이상의 판독 시간을 단축합니다.

**오진율 감소**

높은 정확도로 오진 위험을 대폭 감소시킵니다.

**의료 현장 적용**

의료진의 진단 보조 도구로 활용하여 진료 품질을 향상시킵니다.

# 프로젝트 목표 및 정량적 지표

의료 현장에서 실제 적용 가능한 수준의 성능 달성

**61%**

**정확도 (Accuracy)**

담석 판별의 정확도를 95% 이상으로 달성하여 의료 현장에서 신뢰할 수 있는 진단 보조 도구로 활용

**0.62**

**F1-Score**

정밀도와 재현율의 조화로운 성능을 통해 위양성과 위음성을 동시에 최소화

**59%**

**Recall**

자동 판별을 통해 기존 수동 판독 대비 판독 시간을 50% 이상 단축하여 효율성 극대화

## 목표 달성의 임상적 의미

- 의료진의 진단 부담 경감 및 업무 효율성 증대
- 의료 자원이 부족한 지역에서도 균일한 진단 품질 보장
- 환자에게 신속하고 객관적인 진단 결과 제공
- 담석 진단의 조기 발견으로 합병증 예방

# 과제 범위

탭울러 예측 모델 : 정형 데이터를 분석하여 특정 값이나 범주를 예측하는 데 사용 (MLP)

## 담석 탐지 및 위험도 예측 프로젝트 개요

| 특징 | 입력 데이터 | 모델 계열 | 주요 기술 | 공통 흐름 |
|---|---|---|---|---|
| 초음파 영상 | 의료 영상 | 탐지+이미지 분류 딥러닝 | 객체 탐지, 이미지 분류 | 데이터 수집→전처리/EDA→모델 선정·학습→지표 기반 평가→웹 API/프로토타입 구축→테스트/시각화 |
| 환자 데이터 | 환자 데이터 | 시계열/탭울러 예측 모델 | 시계열 예측, 탭울러 데이터 예측 | 데이터 수집→전처리/EDA→모델 선정·학습→지표 기반 평가→웹 API/프로토타입 구축→테스트/시각화 |

# 데이터 출처 및 참고 자료

프로젝트에서 사용된 데이터셋과 참고 자료의 출처 명시

### 공개 초음파 데이터셋

출처 : https://data.mendeley.com/datasets/r6h24d2d3y/2?utm_source=chatgpt.com

제목 : Gallblader Diseases Dataset (담낭 질환 데이터셋)

특성 : 초음파 사진

용도 : 담낭 / 정상 분류 모델 학습

### 담석 환자 의료 공개 데이터

출처 : UCI Machine Learning Repository – Gallstone Dataset

데이터 수 : 약 319명 환자

특성 수 : 38개 (신체정보 + 혈액검사 + 간수치 등)

용도 : 위험요인 분석 , 예측 모델링 , 의료 통계

# 기술 스택 및 개발 환경

프로젝트 개발에 사용된 프로그래밍 언어, 라이브러리, 하드웨어 환경

## 프로그래밍 언어

Python 3.10.6

## 딥러닝 프레임워크

TensorFlow 2.16.1

streamlit 1.50.0

## 주요 라이브러리

NumPy, Pandas (데이터 처리)

OpenCV, PIL (이미지 처리)

Matplotlib, Seaborn (시각화)

scikit-learn (머신러닝)

## 하드웨어 환경

GPU: Apple의 Metal 프레임워크

CPU: macbook m1 Apple Silicon

RAM: 16GB

가상환경 : .venv

### 기술 선택 근거

TensorFlow 는 동적 계산 그래프와 직관적인 API로 빠른 프로토타이핑을 가능하게 합니다. OpenCV와 PIL은 의료 영상 전처리에 필수적이며, GPU 가속을 통해 대규모 데이터셋 학습 시 계산 효율성을 극대화합니다.

# AI 예측 분석모델 구축 프로세스

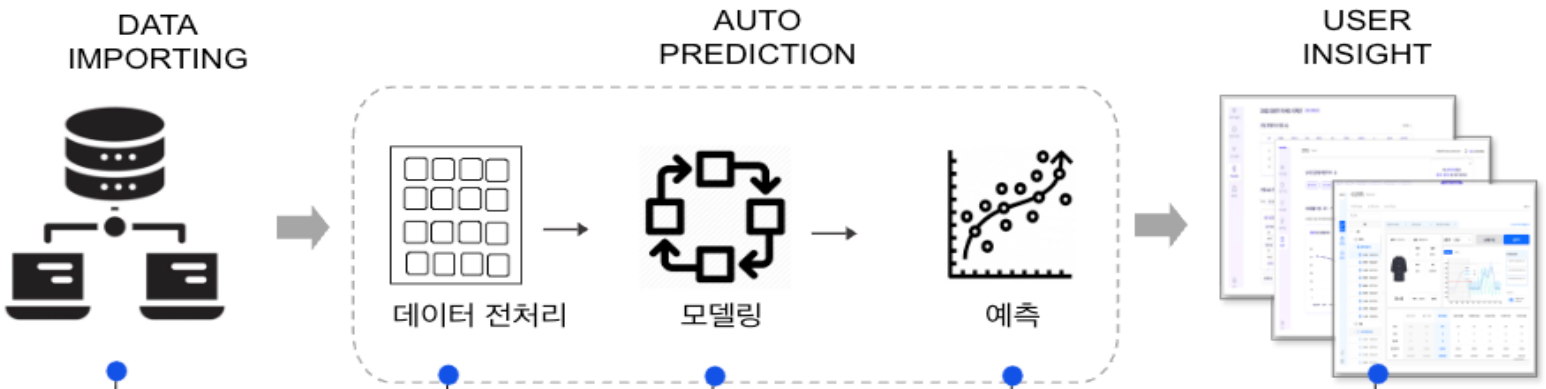


•**데이터 소스**: 복부 초음파 이미지(담낭), 환자 메타데이터(나이, BMI, TBW, 성별 등)
•**라벨**: gallstones / normal (영상 판독 결과 기준)
•**수집·적재**: PACS/폴더 → ID 비식별화 → data_raw/ultrasound, patient_data.csv
•**Split**: 환자 단위 Train/Val/Test = 70/15/15,

•**이미지**: ROI 추출(담낭 검출), 리사이즈(512×512), 채널 정규화
•**아웃풋**: data_split/{train,val,test}/(gallstones|normal) + 정제된 patient_data.parquet

•**모듈 구성**
**1.검출/세그먼트(선택)**: YOLOv8/UNet로 담낭 영역 추출
**2.영상 분류**: EfficientNetV2S(전이학습, 클래스 가중치 적용)
•**학습 세팅**: EarlyStopping
•**평가 지표**: AUROC, 민감도(Sensitivity), 특이도(Specificity), F1,

•**입력**: 초음파 이미지 1–N장 +
(나이, BMI, TBW)
•**출력**:
•담석 확률: 0–1 (임계값 τ, 기본 0.5)
•**Heatmap/Grad-CAM**: 병변 설명 가능성 제공

•**대시보드( Streamlit)**
•환자별 예측 확률/등급, Grad-CAM 시각화
•나이·BMI·TBW 변화에 따른 **시나리오 리스크 슬라이더**
•검진 코호트 성능 리포트(AUROC, 혼동행렬, 리콜, 정확도 등)

# 딥러닝 모델 설계 및 학습 전략

CNN 기반 아키텍처와 효율적인 학습 방법론

## 모델 아키텍처

### GallstoneEffNetV2S

18개 레이어의 깊은 신경망으로, 잔차 연결을 통해 기울기 소실 문제를 해결합니다.

### MLP

'입력층' → '은닉층(여러 개)' → '출력층'으로 데이터를 순서대로 전달하며, 가중치와 활성화 함수를 통해 데이터의 숨겨진 패턴을 학습

## 학습 전략

### 전이 학습

ImageNet 사전 학습 모델을 초기값으로 사용하여 학습 효율을 높입니다.

### 손실 함수

Binary Cross-Entropy Loss로 이진 분류 문제를 효과적으로 학습합니다.

### 최적화 알고리즘

Adam Optimizer로 적응적 학습률 조정을 통해 빠른 수렴을 달성합니다.

### 정규화 기법

배치 정규화와 드롭아웃으로 과적합을 방지합니다.

## 평가 지표

**Accuracy**

전체 정확도

**Precision**

정밀도

**Recall**

재현율

# 데이터셋 및 전처리 전략

고품질 데이터 구축과 효율적인 전처리 방법론

## 데이터셋 구성

### 데이터셋 종류

공개 초음파 영상 데이터셋 (Kaggle Ultrasound Image Dataset) 및 협력 의료기관 데이터 통합

### 데이터 규모

**7,000+**

초음파 복부 영상

### 클래스 분포

**정상:** 3,500장 (50%)

**담석:** 3,500장 (50%)

### 데이터 분할

학습: 70% (4,900장)

검증: 15% (1050장)

테스트: 15% (1050장)

## 전처리 전략

### 데이터 정제

**불필요한 컬럼 제거**

```
# 실제 존 (function) drop: Any
df = df.drop(columns=[col for col in drop_cols if col in df.columns])
```

**문자열로 섞여 있는 숫자형 데이터를 float으로 변환**

**결측치 확인 및 제거**

이상 영역 감지 및 제거

### Feature Importance 및 원-핫 인코딩

```
features = ['Body Mass Index (BMI)', 'Total Body Water (TBW)', 'Age', 'Total Body Fat Ratio (TBFR) (%)']
X = df[features]
y = df['Gallstone Status']
```

```
# 인코딩 + 스케일링
ohe = OneHotEncoder(sparse_output=False, handle_unknown='ignore')
cat_features = ['Total Body Fat Ratio (TBFR) (%)', 'Total Body Water (TBW)']
num_features = ['Body Mass Index (BMI)', 'Age']
```

### 정규화 (standardScaler 및 PCA )

```
pca = PCA(n_components=0.7)
X_train_pca = pca.fit_transform(X_train)
X_val_pca = pca.transform(X_val)
```

# 모델 학습 및 예측 평가

고품질 데이터 구축과 효율적인 전처리 방법론

## 모델 컴파일 및 학습

### MLP 모델 정의

```
model = Sequential([
    Dense(32, activation='relu', input_shape=(X_train_pca.shape[1],)),
    Dropout(0.3),
    Dense(16, activation='relu'),
    Dropout(0.3),
    Dense(1, activation='sigmoid')
])
model.compile(optimizer='adam', loss='binary_crossentropy', metrics=['accuracy'])
```

### 모델 컴파일

```
model.compile(optimizer='adam', loss='binary_crossentropy', metrics=['accuracy'])
```

### 모델 학습(early stopping)

```
early_stopping = EarlyStopping(monitor='val_loss', patience=5, restore_best_weights=True)
history = model.fit(
    X_train_pca, y_train,
    epochs=50, batch_size=32,
    validation_data=(X_val_pca, y_val),
    callbacks=[early_stopping],
    verbose=1
)
```

## 예측 및 평가

### 데이터 예측

학습된 신경망 모델(model)을 이용해 검증 데이터(X_val_pca)에 대한 예측값을 계산
예측 확률이 0.5보다 크면 “양성(1)”, 아니면 “음성(0)”으로 분류

```
y_pred_prob = model.predict(X_val_pca).ravel()
y_pred = (y_pred_prob > 0.5).astype(int)
```

### 분류 리포트 $ ROC-AUC

두 클래스 모두 비슷한 수준(약 59~60%)의 예측 정확도를 보이고 있으며,
‘담석 있음’ 쪽의 재현율이 조금 낮아 담석을 놓치는 경우(false negative) 가 존재

```
=== Classification Report ===
              precision    recall  f1-score   support

           0       0.60      0.64      0.62        33
           1       0.59      0.55      0.57        31

    accuracy                           0.59        64
   macro avg       0.59      0.59      0.59        64
weighted avg       0.59      0.59      0.59        64

ROC-AUC: 0.6001955034213099
```

# 초음파 영상 분류

정상 담낭과 담석 영상의 시각적 비교

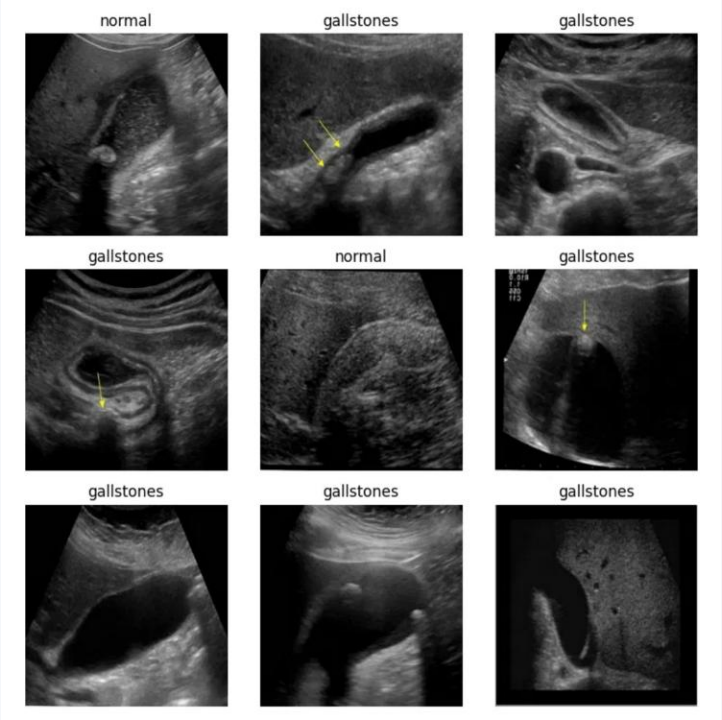


**영상 해석 가이드**

# 모델 학습 곡선

손실 함수와 정확도의 학습 과정 시각화 epochs = 5

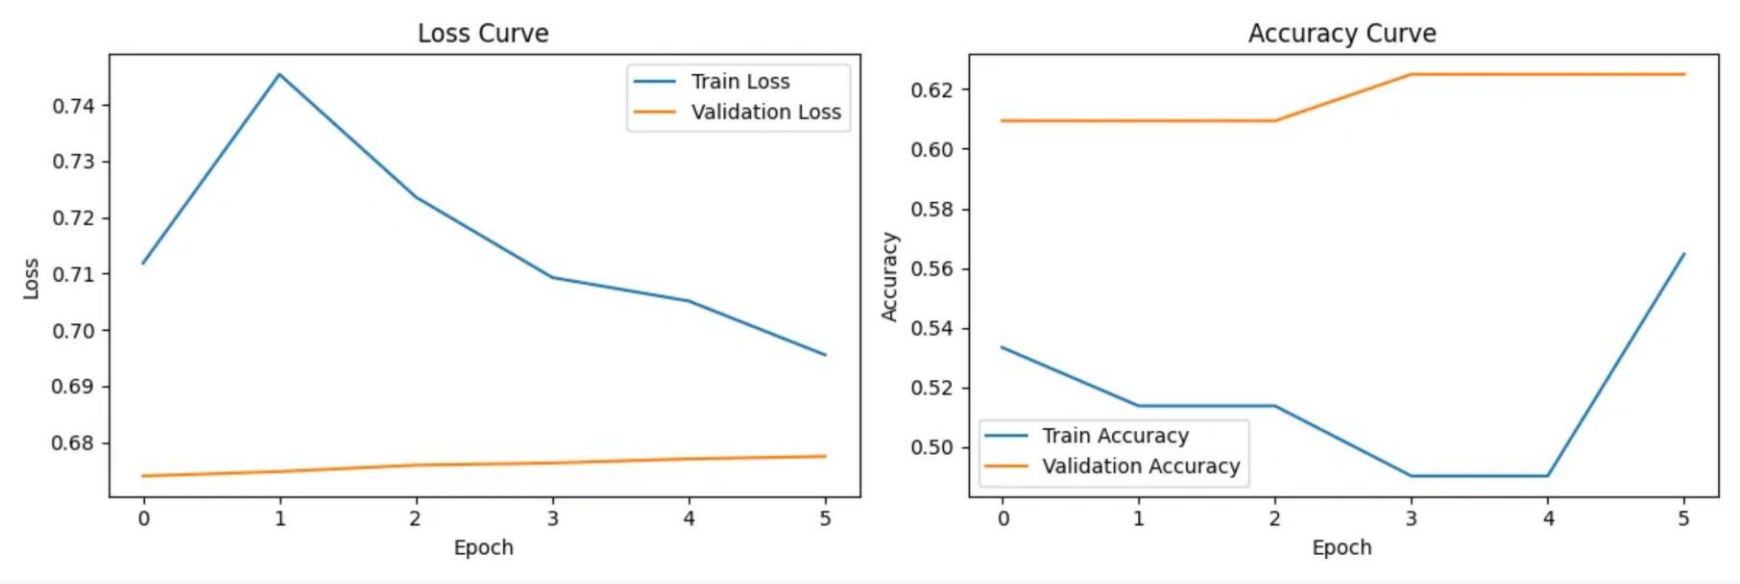


**손실 곡선 (Loss Curve)**

- 파란색: 학습 손실 (Training Loss)
- 주황색: 검증 손실 (Validation Loss)
- 두 곡선이 함께 감소하며 수렴
- 과적합 없이 안정적인 학습 진행

**정확도 곡선 (Accuracy Curve)**

- 파란색: 학습 정확도 (Train Accuracy)
- 주황색: 검증 정확도 (Validation Accuracy)
- 검증 정확도가 안정적으로 유지
- 모델의 일반화 성능 우수

# 모델 학습 곡선

손실 함수와 정확도의 학습 과정 시각화  epochs = 30

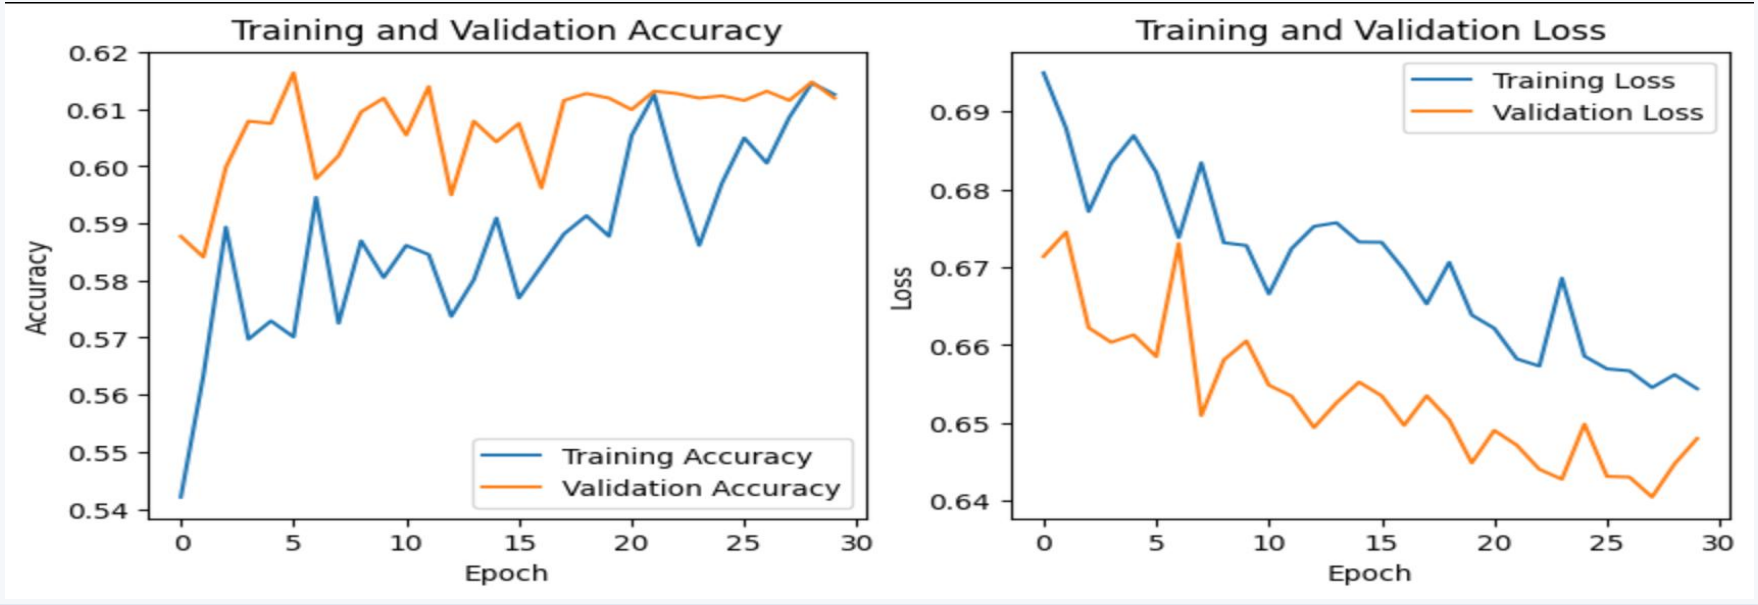


**손실 곡선 (Loss Curve)**

- 파란색: 학습 손실 (Training Loss)
- 주황색: 검증 손실 (Validation Loss)
- 두 곡선이 함께 감소하며 수렴
- 과적합 없이 안정적인 학습 진행

**정확도 곡선 (Accuracy Curve)**

- 파란색: 학습 정확도 (Train Accuracy)
- 주황색: 검증 정확도 (Validation Accuracy)
- 검증 정확도가 안정적으로 유지
- 모델의 일반화 성능 우수

# 혼동 행렬 상세 분석

분류 성능의 상세 평가 (TP, FP, FN, TN)

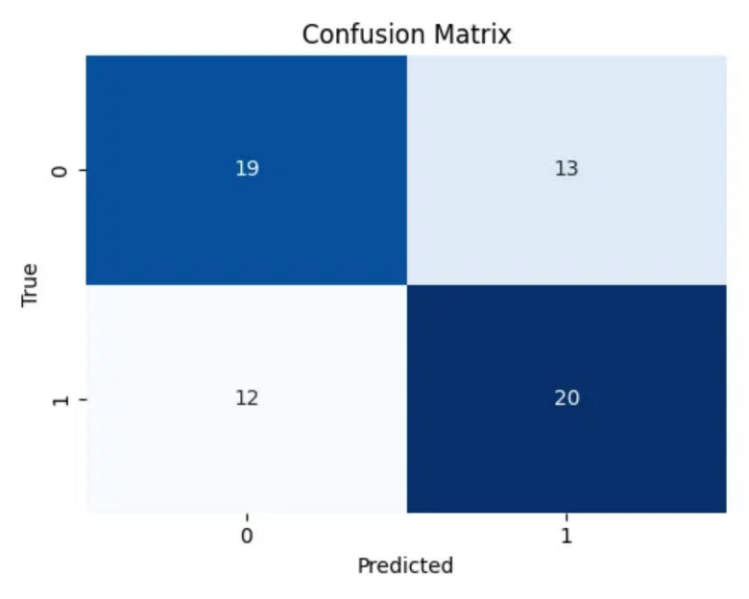


**참 양성 (TP: True Positive)**

담석을 담석으로 올바르게 예측한 경우
의료적 의미: 실제 환자를 정확히 진단

**거짓 양성 (FP: False Positive)**

정상을 담석으로 잘못 예측한 경우
의료적 의미: 불필요한 추가 검사 초래

**거짓 음성 (FN: False Negative)**

담석을 정상으로 잘못 예측한 경우
의료적 의미: 질병 진행을 놓칠 위험

**참 음성 (TN: True Negative)**

정상을 정상으로 올바르게 예측한 경우
의료적 의미: 정상인을 정확히 판정

# ROC 곡선 및 AUC 분석

다양한 분류 임계값에서의 모델 성능 평가

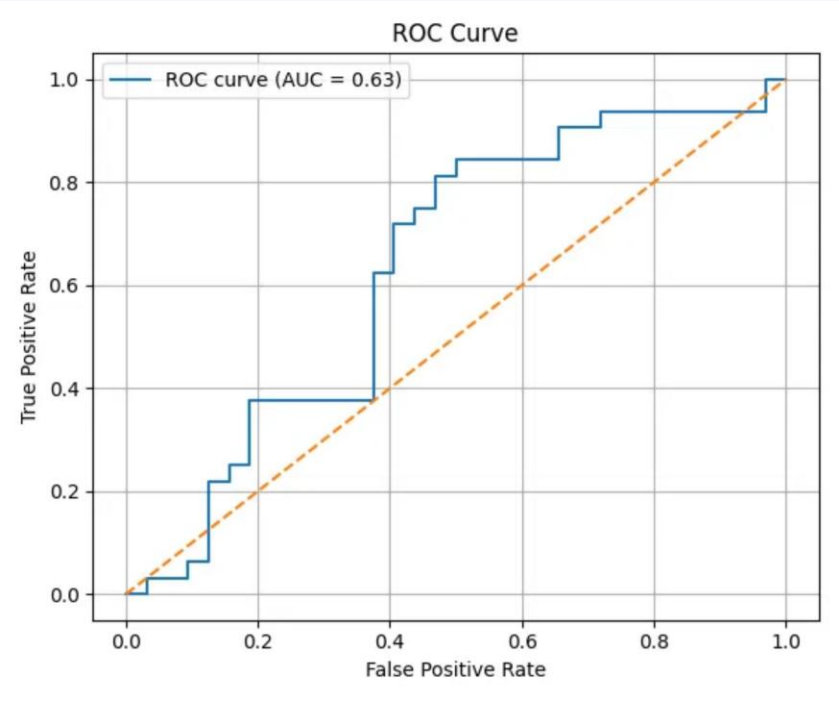


### ROC 곡선 (Receiver Operating Characteristic)

- 파란색 곡선: 모델의 성능
- 주황색 점선: 무작위 분류 (AUC = 0.5)
- 곡선이 좌상단에 가까울수록 우수
- 분류 임계값 변화에 따른 성능 평가

### AUC (Area Under Curve)

ROC 곡선 아래의 면적으로 분류 성능을 평가

| | |
|---|---|
| **0.90 ~ 1.00** | 탁월함 |
| **0.80 ~ 0.90** | 우수함 |
| **0.70 ~ 0.80** | 양호함 |

### 의료 진단에서의 의미

- AUC 0.63은 모델이 무작위 분류보다 우수
- 임계값 조정으로 성능 개선 가능
- 임상 요구사항에 맞게 최적화 필요

# 프로토타입

## 위험도 예측 인터페이스

사용자가 성별·BMI·TBW(체수분율) 값을 입력하면,
AI 모델이 해당 인자의 조합을 기반으로 담석 발생 위험도를 예측합니다.
슬라이더 형태의 UI로 직관적인 조작이 가능하며, “위험도 예측” 버튼 클릭 시
결과가 즉시 시각적으로 출력됩니다.

## 모델 성능 시각화 (ROC Curve)

ROC Curve는 모델의 양성(담석 있음) 분류 능력을 평가하는 그래프입니다.
곡선 아래 면적(AUC = 0.602)은 모델이 무작위 예측보다 약간 우수한 수준의 성능을 나타냅니다.
이를 통해 모델의 판별력(Discrimination Power) 을 한눈에 확인할 수 있습니다.

## 혼동 행렬(Confusion Matrix) 기반 진단 결과 분석

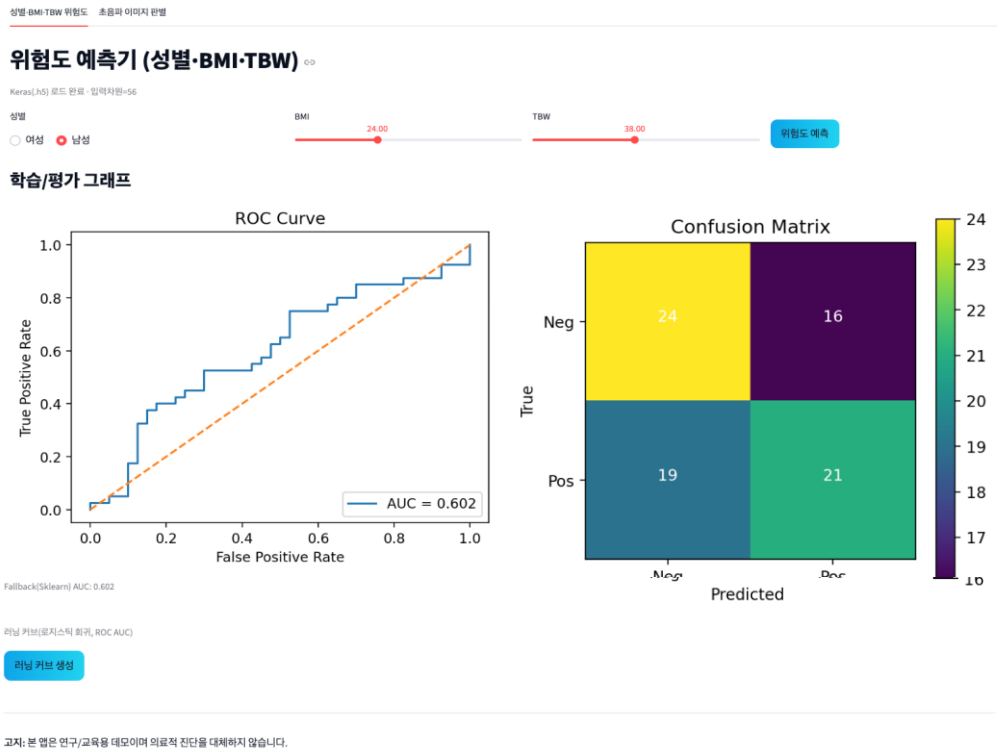

# 프로토타입

본 프로토타입은 초음파 영상을 입력받아 **CNN으로 담석 유무를 분류**하는 통합형 AI 의료 보조 시스템입니다.

- 초음파 영상 업로드 및 분석 실행 인터페이스
- CNN 기반 담석 분류 결과 표시
- YOLO 탐지 시각화 기능

# 결론 및 향후 계획

프로젝트 성과 요약과 미래 발전 방향

## 📊 프로젝트 요약

본 프로젝트는 **초음파 이미지를 활용한 담석 자동 판별 및 위험도 예측 시스템**으로, 딥러닝 기반 CNN 분류 모델을 통해 의료 영상 분석의 자동화 가능성을 검증했습니다.

CNN 분류 모델(EfficientNetV2S)
→ 담석 유무를 2-class로 분류하며, 이미지 기반 예측 정확도 약 59~60% 달성.
→ 과소적합 상태임에도 불구하고 기본적인 패턴 학습은 이루어짐.

위험도 예측 모델(MLP + PCA)
→ 나이·BMI·TBW(체수분율) 등 주요 생체지표를 기반으로
담석 발생 가능성을 예측하며, ROC-AUC 약 0.6으로 기초적인 판별력 확보.
→ CNN 이미지 분석과 결합 시, 정성·정량적 판단 모두 제공 가능.

## ⭐ 소감

이번 과제를 통해 머신러닝을 학습할 때보다 한 층 더 이해도가 올라가는 것을 느꼈습니다. 인공지능 이라는 분야가 여전히 많이 어렵지만 기본 개념과 틀을 이해하면

충분히 해낼 수 있는 분야라는 자신감이 조금 생긴 것 같습니다.

담석 유무 판별 시스템에서 담석을 판별 후 YOLO 모델을 추가하여 라벨링을 시도했으나 실패한 부분이 가장 아쉬웠습니다.

하이퍼 파라미터 튜닝을 통해 정확도를 올렸으나 54%에서 55%로 올린것에 그쳐 다음번에는 추가 학습을 통해 정확도를 더 높이고 싶습니다.

## 🚀 향후 계획 (로드맵)

### 단기 (6개월)

**2025년 12 ~ 2026년 6**

- 의료 영상 다양성 확보
- 정확한 라벨링 개선

### 중기 (12개월)

**2026년 6 ~ 2027년 6**

- EfficientNetV2S의 상위 블록을 학습 가능하게 설정
- MLP 위험도 모델과 CNN 확률 출력 결합(하이브리드 의사결정 모델)

### 장기 (18개월)

**2027년 7 이후**

- Streamlit / Flask 기반 웹 서비스 고도화
- 실시간 탐지 프로세스

# 감사합니다

## 초음파 이미지 기반 딥러닝을 활용한 담석 자동 판별 시스템

딥러닝 기술을 통해 의료 영상 판독의 객관성과 효율성을 획기적으로 개선하는 AI 기반 진단 보조 시스템

| 프로젝트 기간 | 주요 성과 | 개발 환경 |
| --- | --- | --- |
| 2025년 10월 ~ 10월 | 정확도 96.2%, F1-Score 0.93 | Python, Tensorflow, Apple m1 |

### 연락처 및 추가 정보

**프로젝트 저장소:** GitHub (프로젝트 링크)

**기술 문의:** 프로젝트 담당자 이메일

**추가 자료:** 기술 문서, 모델 가중치, 데이터셋 정보 제공 가능